



دانشگاه بین المللی امام خمینی

دانشکده فنی مهندسی

پروژه پایانی درس هوش محاسباتی

پیاده سازی Pipeline استاندارد MLOps برای پیش بینی ریزش مشتری

نگارش:

پارسا بشارتی

استاد درس:

دکتر مهدی باحقیقت

تیر

۱۴۰۵

فهرست

۲	معرفی پروژه
۲	نسخه‌های مختلف دیتاست
۲	مراحل پیش پردازش داده‌ها
۳	Feature Engineering
۳	مدل‌های استفاده شده
۴	پارامترهای انتخاب شده
۴	نتایج و مقایسه مدل‌ها
۵	ثبت آزمایش‌ها در MLflow
۶	کنترل نسخه پروژه
۸	استقرار مدل با Docker
۸	جمع‌بندی

معرفی پروژه

هدف از انجام این پروژه، طراحی و پیاده‌سازی یک خط لوله کامل MLOps برای پیش‌بینی ریزش مشتریان (Customer Churn Prediction) بود. در این پروژه علاوه بر آموزش مدل‌های یادگیری ماشین، تلاش شد تمام مراحل مورد نیاز از آماده‌سازی داده تا ثبت آزمایش‌ها، نسخه‌بندی مدل و استقرار مدل نهایی نیز پیاده‌سازی شود.

برای این منظور از مجموعه داده Telco Customer Churn استفاده شد. پس از انجام مراحل پیش‌پردازش و Feature Engineering، چند مدل مختلف آموزش داده شدند و نتایج آن‌ها با یکدیگر مقایسه شد. سپس تمامی آزمایش‌ها در MLflow ثبت شدند و بهترین مدل با استفاده از Docker به صورت یک سرویس قابل استفاده درآمد.

نسخه‌های مختلف دیتاست

در طول پروژه، داده‌ها در چند مرحله مورد استفاده قرار گرفتند تا تغییرات اعمال شده روی آن‌ها قابل مدیریت باشد.

در نسخه اولیه، داده خام شامل اطلاعات مشتریان، نوع خدمات، مبلغ پرداختی، مدت زمان همکاری و وضعیت ریزش بود.

در نسخه دوم، عملیات پاکسازی داده‌ها انجام شد. مقادیر گم‌شده حذف یا اصلاح شدند و نوع داده برخی ستون‌ها نیز تغییر پیدا کرد.

در نسخه سوم، علاوه بر پاکسازی، ویژگی‌های جدید ایجاد شدند و داده‌ها برای آموزش مدل آماده شدند. این نسخه به عنوان نسخه نهایی دیتاست در فرآیند آموزش مورد استفاده قرار گرفت.

مراحل پیش‌پردازش داده‌ها

قبل از آموزش مدل‌ها، چند مرحله پیش‌پردازش روی داده‌ها انجام شد تا کیفیت داده‌ها افزایش پیدا کند.

در ابتدا ستون Total Charges که به صورت رشته ذخیره شده بود به مقدار عددی تبدیل شد و سطرهایی که دارای مقدار نامعتبر بودند حذف شدند.

در ادامه ستون Customer ID که تأثیری در فرآیند یادگیری نداشت کنار گذاشته شد.

ویژگی هدف پروژه نیز ستون Churn Value بود که مشخص می کرد هر مشتری در آینده سرویس را ترک می کند یا خیر.

برای تبدیل ویژگی های متنی به ویژگی های قابل استفاده توسط مدل های یادگیری ماشین از روش One-Hot Encoding استفاده شد. به این ترتیب تمام ستون های دسته ای به ستون های عددی تبدیل شدند.

در پایان نیز داده ها به سه بخش آموزش، اعتبارسنجی و آزمون تقسیم شدند تا بتوان عملکرد مدل را به صورت دقیق ارزیابی کرد.

Feature Engineering

پس از پایان مراحل اولیه، چند ویژگی جدید نیز به داده ها اضافه شد تا مدل اطلاعات بیشتری از رفتار مشتریان دریافت کند.

اولین ویژگی میانگین هزینه ماهانه بود که از تقسیم مبلغ کل پرداختی بر مدت زمان همکاری مشتری محاسبه شد.

ویژگی دوم مشخص می کرد آیا مشتری جدید است یا خیر. برای این کار مشتریانی که مدت همکاری کمی داشتند در گروه مشتریان جدید قرار گرفتند.

ویژگی سوم نیز مشخص می کرد که آیا مبلغ پرداختی مشتری از میانگین کل بیشتر است یا خیر.

اضافه شدن این ویژگی ها باعث شد مدل بتواند الگوهای رفتاری مشتریان را بهتر یاد بگیرد و عملکرد مناسبی روی داده های آزمون داشته باشد.

مدل های استفاده شده

برای مقایسه عملکرد الگوریتم های مختلف، چهار مدل یادگیری ماشین آموزش داده شدند.

اولین مدل Logistic Regression بود که به عنوان یک مدل پایه مورد استفاده قرار گرفت. مدل دوم Random Forest بود که با استفاده از مجموعه‌ای از درخت‌های تصمیم عمل می‌کند. مدل سوم XGBoost بود که یکی از الگوریتم‌های محبوب Boosting محسوب می‌شود و معمولاً عملکرد مناسبی در مسائل طبقه‌بندی دارد. در نهایت نیز مدل CatBoost آموزش داده شد که برای داده‌های جدولی طراحی شده است. برای همه مدل‌ها از Grid Search و Cross Validation جهت انتخاب بهترین پارامترها استفاده شد.

پارامترهای انتخاب شده

برای هر مدل مجموعه‌ای از پارامترها مورد بررسی قرار گرفت و بهترین مقدار آن‌ها بر اساس امتیاز Cross Validation انتخاب شد. برای مدل Logistic Regression مقدار C برابر با ۱۰ انتخاب شد. برای Random Forest تعداد درخت‌ها برابر با ۱۰۰ و بیشترین عمق درخت‌ها برابر با ۱۰ در نظر گرفته شد. برای مدل XGBoost نیز تعداد درخت‌ها ۱۰۰، عمق درخت ۳ و نرخ یادگیری ۰.۱ انتخاب شد. در مدل CatBoost نیز بهترین نتیجه با عمق ۴ و نرخ یادگیری ۰.۰۱ به دست آمد. تمامی این اطلاعات در MLflow ثبت شدند تا امکان مقایسه آزمایش‌ها وجود داشته باشد.

نتایج و مقایسه مدل‌ها

پس از آموزش مدل‌ها، عملکرد آن‌ها روی داده‌های اعتبارسنجی و آزمون بررسی شد. در مقایسه انجام شده، مدل Logistic Regression بهترین عملکرد را از نظر معیار F1-Score روی داده آزمون داشت و به عنوان مدل نهایی پروژه انتخاب شد. مدل‌های XGBoost و CatBoost نیز نتایج مناسبی داشتند اما اختلاف کمی با مدل نهایی داشتند. مدل Random Forest نسبت به سایر مدل‌ها عملکرد ضعیف‌تری نشان داد.

این موضوع نشان می‌دهد که در این مجموعه داده، یک مدل خطی ساده توانسته است عملکردی قابل قبول و حتی بهتر از مدل‌های پیچیده‌تر داشته باشد.

ثبت آزمایش‌ها در MLflow

برای مدیریت آزمایش‌ها از MLflow استفاده شد.

در هر بار آموزش مدل، اطلاعاتی مانند نام مدل، پارامترهای انتخاب‌شده، معیارهای ارزیابی و فایل مدل در MLflow ثبت شدند.

به این ترتیب امکان مشاهده تمامی اجراها، مقایسه نتایج و انتخاب بهترین مدل فراهم شد.

Customer Churn Prediction [Provide Feedback](#) [Add Description](#)

Runs Evaluation **Experimental** Traces

Time created State: Active Datasets

Sort: Created Columns Group by

☐	Run Name	Created	Dataset	Duration	Source	Models
☐	CatBoost	39 minutes ago	-	2.2s	run_pipe...	catboost
☐	XGBoost	40 minutes ago	-	2.9s	run_pipe...	xgboost
☐	Random Forest	40 minutes ago	-	3.1s	run_pipe...	sklearn
☐	Logistic Regression	40 minutes ago	-	4.4s	run_pipe...	sklearn
☐	CatBoost	12 hours ago	-	3.2s	run_pipe...	catboost
☐	XGBoost	12 hours ago	-	5.1s	run_pipe...	xgboost
☐	Random Forest	12 hours ago	-	4.3s	run_pipe...	sklearn
☐	Logistic Regression	12 hours ago	-	5.3s	run_pipe...	sklearn
☐	Logistic Regression	13 hours ago	-	48ms	run_pipe...	-
☐	CatBoost	13 hours ago	-	3.3s	train.py	catboost
☐	XGBoost	13 hours ago	-	5.1s	train.py	xgboost
☐	Random Forest	13 hours ago	-	4.1s	train.py	sklearn

Logistic Regression

Overview Model metrics System metrics Traces Artifacts

Details

Created at	07/07/2026, 02:02:01 PM
Created by	Parsa
Experiment ID	378763811504069443 
Status	 Finished
Run ID	9a34028c74ee4c918b6f7b1f82e7f11c 
Duration	4.4s
Datasets used	—
Tags	Add tags
Source	 run_pipeline.py  7c8f428
Logged models	 sklearn
Registered models	—
Registered prompts	—

Metrics (11)

 Search metrics	
Metric	Value
cv_f1	0.6239095781087766
test_accuracy	0.7876777251184834
test_f1	0.5867158671586716
test_precision	0.6068702290076335
test_recall	0.5678571428571428
test_roc_auc	0.8343387096774194
val_accuracy	0.8236966824644549
val_f1	0.654275092936803
val_precision	0.6848249027237354
val_recall	0.6263345195729537
val_roc_auc	0.8569316854717831

Parameters (5)

 Search parameters	
Parameter	Value
best_model	True
C	10
dataset_version	v3
model	Logistic Regression
seed	42

کنترل نسخه پروژه

تمام فایل‌های پروژه در GitHub نگهداری شدند.

در طول توسعه پروژه، تغییرات مختلف به صورت Commit ثبت شدند تا روند پیشرفت پروژه مشخص باشد و در صورت نیاز بتوان به نسخه‌های قبلی بازگشت.

Public

Pin
 Watch 0

main
1 Branch
0 Tags

Add file
Code

parsa83besharati docker implementation e3aadf1 · 30 minutes ago 9 Commits		
catboost_info	model training and evaluation	14 hours ago
data	features and dataset v3	15 hours ago
deployment_model	docker implementation	30 minutes ago
src	docker implementation	30 minutes ago
.dockerignore	docker implementation	30 minutes ago
.gitignore	Structure	15 hours ago
Dockerfile	docker implementation	30 minutes ago
README.md	Initial commit	15 hours ago
request.json	docker implementation	30 minutes ago
requirements.txt	Structure	15 hours ago
run_pipeline.py	docker implementation	30 minutes ago
sample.json	docker implementation	30 minutes ago

Commits on Jul 7, 2026

docker implementation

parsa83besharati committed 30 minutes ago

training pipeline, MLflow logging and experiment tracking

parsa83besharati committed 13 hours ago

mlflow utils

parsa83besharati committed 14 hours ago

model training and evaluation

parsa83besharati committed 14 hours ago

model training, cross validation

parsa83besharati committed 14 hours ago

features and dataset v3

parsa83besharati committed 15 hours ago

data loader, preprocessing and dataset ver2

parsa83besharati committed 15 hours ago

Commits on Jul 6, 2026

Structure

parsa83besharati committed 15 hours ago


Initial commit

parsa83besharati authored 15 hours ago

لینک گیت هاب


استقرار مدل با Docker

پس از انتخاب بهترین مدل، مدل ذخیره شده در MLflow در قالب یک Docker Image بسته بندی شد. سپس یک Docker Container اجرا شد که مدل را به صورت یک API در اختیار کاربر قرار می دهد. در ادامه با ارسال درخواست HTTP به آدرس سرویس، پیش بینی ریزش مشتری انجام شد و پاسخ به درستی دریافت گردید.



The screenshot shows the 'Images' tab in the MLflow interface. It displays a table of Docker images. The table has columns for Name, Tag, Image ID, Created, Size, and Actions. One image is listed: 'mlops' with tag 'latest', Image ID 'ae4eee789716', created '8 minutes ago', and size '1.73 GB'. The interface also shows a search bar, a refresh button, and a status bar indicating '0 Bytes / 3.64 GB in use' and '3 Images'.

	Name	Tag	Image ID	Created	Size	Actions
☐	mlops	latest	ae4eee789716	8 minutes ago	1.73 GB	



The screenshot shows the 'Containers' tab in the MLflow interface. It displays a table of running containers. The table has columns for Name, Container ID, Image, Port(s), CPU (%), Last star, and Actions. One container is listed: 'goofy_cartwrigl' with Container ID '9c05b8d1f204', Image 'mlops', Port(s) '5001:5001', CPU (%) '0.36%', and Last star '6 minute'. The interface also shows a search bar, a toggle for 'Only show running containers', and a status bar indicating 'Container CPU usage 0.30% / 1200% (12 CPUs available)' and 'Container memory usage 314.9MB / 7.4GB'.

	Name	Container ID	Image	Port(s)	CPU (%)	Last star	Actions
☐	goofy_cartwrigl	9c05b8d1f204	mlops	5001:5001	0.36%	6 minute	

جمع بندی

در این پروژه یک چرخه کامل MLOps از مرحله آماده سازی داده تا استقرار مدل پیاده سازی شد.

استفاده از MLflow باعث شد تمامی آزمایش‌ها و مدل‌ها به صورت منظم ثبت شوند و امکان مقایسه آن‌ها فراهم شود. همچنین استفاده از Docker موجب شد مدل نهایی به راحتی روی سیستم‌های مختلف قابل اجرا باشد.

در نهایت مدل Logistic Regression به عنوان بهترین مدل انتخاب شد و با موفقیت به صورت یک سرویس قابل استفاده مستقر گردید. این پروژه نشان داد که استفاده از ابزارهای MLOps علاوه بر افزایش نظم در فرآیند توسعه، استقرار و نگهداری مدل‌های یادگیری ماشین را نیز بسیار ساده‌تر می‌کند.